

Detecção de Fraudes: Uma Revisão Sistemática

Jean Avila Rangel¹, Maria Claudia Figueiredo Pereira Emer¹,
Adolfo Gustavo Serra Seca Neto¹

¹Universidade Tecnológica Federal do Paraná (UTFPR)
Avenida Sete de Setembro 3165 – 80230-901 – Curitiba – PR – Brazil

jean.rangel94@hotmail.com, mciemer@gmail.com, adolfo@dainf.ct.utfpr.edu.br

Abstract. *Fraudulent activity is an action made by a person or a group of people aiming to gain resources in an illicit manner. This article presents a systematic review of the literature in the state of the art in the area of fraud detection. These results suggest that most authors divide the problem into areas where fraud occurs most often. The most cited areas were frauds on credit cards, insurance and telecommunications systems. Within each area, specific technical computing is used for each situation. This work identified, categorized and presented technical areas guided by previous studies. The main techniques were identified using supervised and unsupervised algorithms. As a contribution, this article presents a discussion on the subject, where the possibility of future research was found as benchmarks to compare tests of algorithms and tools used to locate fraud in public sectors applied, some covered in the studies found.*

Resumo. *Uma atividade fraudulenta é uma ação realizada por uma pessoa ou um grupo de pessoas visando obter vantagem individual sobre determinado serviço ou recurso. Este artigo apresenta uma revisão sistemática na literatura para estudar o Estado da Arte na área de detecção de fraudes e identificar os tipos e técnicas empregadas. Os resultados obtidos sugerem que a maior parte dos autores divide o problema em áreas onde as fraudes ocorrem com maior frequência. As áreas mais citadas foram fraudes em cartões de crédito, em seguradoras e em sistemas de telecomunicação. Dentro de cada área, técnicas específicas da computação são utilizadas para cada situação. Este trabalho identificou, categorizou e apresentou as técnicas e áreas mais abordadas pelos estudos anteriores. As principais técnicas constatadas foram as que utilizam algoritmos supervisionados e não-supervisionados. Como contribuição, este artigo apresenta uma discussão sobre o assunto, onde foi constatada a possibilidade de futuras investigações, como propor benchmarks para padronizar os testes aplicados nos algoritmos e utilizar ferramentas para localizar fraudes em órgãos públicos, pouco abordados nos estudos encontrados.*

1. Introdução

A detecção de fraudes é utilizada para resolver problemas variados, geralmente para reduzir falhas de segurança em sistemas onde há gasto de recursos com usuários mal intencionados.

A resolução do problema é obtida, em grande parte, com recursos computacionais. Mais especificamente, a área de mineração de dados é aplicada, utilizando conhecimentos da estatística, matemática e aprendizado de máquina. [Wongchinsri and Kuratach 2016]

Em todo contexto organizacional, cada ambiente possui um tipo de tratamento e armazenamento de dados. Portanto, ambientes podem possuir dados organizados de maneira estável por induzirem normativas e tecnologias padronizadas ou fazer exatamente o contrário, possuindo dados desorganizados com poucas conexões lógicas. Desta maneira, este estudo visa conhecer abordagens gerais e adaptáveis em detecção de fraudes.

O controle organizacional de uma empresa ou setor pode garantir a sua boa estabilidade. Soluções para detectar, prevenir e evitar fraudes podem se tornar uma ferramenta para auxiliar a economia de recursos [Chan et al. 1999].

A detecção de fraudes vem sendo utilizada há muito tempo para controle organizacional e econômico [Seyedhossein and Hashemi 2010]. Em estudos realizados no estado da arte, houve uma grande apresentação sobre algoritmos para detectar fraudes em sistemas financeiros ou de cartão de crédito [Chan et al. 1999], [Chandola et al. 2009] e [Abdallah et al. 2016]

O objetivo geral deste trabalho é realizar uma revisão sistemática para identificar e categorizar técnicas e ferramentas para detecção de fraudes.

Como objetivos específicos, este trabalho busca:

- Descobrir a importância das áreas de mineração de dados e aprendizado de máquina e suas utilizações para detecção de fraudes;
- Examinar se os estudos realizados em detecção de fraudes apresentam oportunidades para áreas pouco ou não abordadas. Caso haja necessidade, o estudo poderá categorizar possibilidades de trabalhos futuros em áreas onde há lacunas no assunto;
- Elencar como os autores validaram suas pesquisas nas áreas de detecção de fraudes;
- Agrupar quais tecnologias foram as mais utilizadas para cada contexto.

A realização da revisão sistemática proposta por este trabalho obtém motivação devido à crescente expansão do Estado da Arte no assunto [Pejic-Bach 2010]. Em pesquisas realizadas em bases de dados por trabalhos realizados na área de detecção de fraude, notou-se grande produção de artigos anteriormente ao ano de 2010, porém com um significativo aumento na porcentagem de publicações posteriores a 2010. Este fator indica o crescimento do interesse da comunidade científica em pesquisar o assunto.

Embora cartões de crédito e sistemas de telecomunicações tenham sido criados há décadas, ainda estão em crescimento de utilização, resultando no aumento de possíveis fraudes e valores podendo gerar prejuízos [Abdallah et al. 2016]. No início dos anos 2000, as palavra chave "*fraud detection*" já contava com mais de 80 patentes registradas [Bolton et al. 2002].

Em trabalhos futuros após este artigo, pretende-se desenvolver, ou utilizar, uma técnica para rastrear fraudes em setores públicos. Com isso, ferramentas de detecção de fraudes seriam aplicadas para descobrir problemas em dados de auditoria e controle em órgãos públicos.

A seguir, na Seção 2, será descrito o referencial teórico que situará o contexto do assunto abordado. Na sequência, a metodologia utilizada para realizar esta revisão sistemática será apresentada e discutida na Seção 3. Apresentando o Estado da Arte, os trabalhos encontrados serão elencados, analisados e discutidos na Seção 4 para o fechamento desta revisão sistemática, onde ocorrerá uma discussão, na Seção 5, e a conclusão, na Seção 6.

2. Referencial Teórico

Esta seção fornece um panorama geral no assunto de detecção de fraudes, situando o problema e relacionado com pesquisas.

A área de detecção de fraudes possui sua base estabelecida no campo da mineração de dados, onde a computação é utilizada para gerar informação a partir de dados coletados, geralmente, de maneira automática. Os dados iniciais não apresentam sentido para seu possuinte e no mundo empresarial, o número de informação tem se mostrado relevante para sucesso de alguma corporação.

A primeira utilização de mineração de dados foi de maneira empírica em setores do comércio, pois as empresas possuíam dados de compra de seus clientes e com o cruzamento das informações conseguiam prever o perfil do usuário.

A Figura 1 apresenta a compreensão de [Fayyad et al. 1996] sobre descoberta de conhecimento em base de dados.

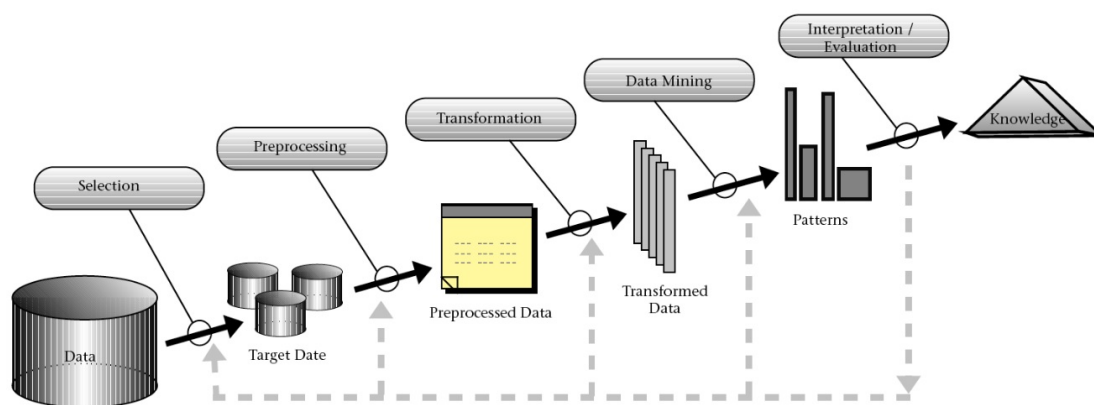


Figura 1. Mineração de dados para ganho de informações. Fonte: [Fayyad et al. 1996]

Na imagem, possuímos um processo evolutivo para a mineração de dados. Inicialmente, os dados de um conjunto são selecionados e separados em conjuntos menores, para melhor manuseio e visibilidade. Em seguida, os dados são pré-processados e transformados para serem legíveis por algoritmos computacionais na etapa de mineração de dados. Após os resultados serem exibidos, um ser humano com conhecimento sobre a base de dados inicial avalia as informações fornecidas pelos algoritmos, para adquirir algum conhecimento que não se possuía até então.

A maior utilização computacional do processo ocorre na etapa de mineração de dados, onde algoritmos complexos são executados para gerar informações. Todavia, o maior gasto temporal se encontra em outras etapas, pois são nelas que é necessário o trabalho manual de um humano para trabalhar com os dados.

Utilizando como exemplo uma rede de supermercados, o caixa eletrônico registra todos os produtos que os clientes comprem na sexta-feira, e como padrão, muitos adquirem itens em comum. Como estratégia de *marketing*, o supermercado pode lucrar mais que o normal após possuir a informação desse novo tipo de perfil identificado, pois pode usar essa informação a seu favor.

A área de detecção de fraudes obteve início em pesquisas nas áreas da estatística e da matemática. No âmbito computacional, [Fawcett and Provost 1997] realizaram uma das primeiras e principais abordagens encontradas na literatura. Em seus estudos, analisaram e criaram um sistema para detecção de fraudes em sistemas de telecomunicação. Em seus estudos, constaram que indivíduos fraudadores estão constantemente mudando suas táticas para burlar sistemas, que devem ser adaptáveis às novas situações.

De acordo com a Associação dos Examinadores de Fraudes Certificados (Association of Certified Fraud Examiners), a definição de fraude é: o uso de forma incorreta de algum setor ou recurso para o aumento dos benefícios individuais [Abdallah et al. 2016] e [Allan and Zhan 2010].

Idealmente, o custo para detectar uma fraude deve ser menor do que o gasto gerado por ela. Para ilustrar uma situação hipotética, uma empresa fictícia que contém um milhão de dados em um arquivo pode possuir 1% de falsos alarmes. Esta quantia, embora aparentemente pequena, representará para a equipe responsável em avaliar fraudes cerca de 10.000 avisos. Alocar funcionários para verificar cada uma destas informações terá um custo considerável para a empresa e deverá ser comparado com o prejuízo de deixar as fraudes acontecerem.

Posteriormente, utilizando dados reais fornecidos por companhias bancárias, [Chan et al. 1999] realizaram um trabalho em detecção de fraude em cartões de crédito e obtiveram um aumento nos seus resultados em comparação com técnicas de detecções de fraudes utilizadas anteriormente. Nas constatações, indicaram que os métodos mais potentes para detectar fraudes são utilizados em cartões de crédito. Porém as organizações não costumam revelar suas tecnologias de forma aberta, pois possíveis fraudadores podem se aproveitar do conhecimento e utilizar sistemas com má fé.

Segundo [Fawcett and Provost 1997], há muitas técnicas para detecção de fraudes. As mais difundidas e utilizadas são as que produzem detecções por meio de regras pré estabelecidas e as que elaboram a comparação entre valores de dados. Estas classificações geraram duas ramificações iniciais em pesquisas da área.

Uma das ramificações, a detecção de fraude por meio de regras, determina que uma fraude será detectada devido ao conhecimento que a equipe adquiriu observando fraudes recorrentes em outrora.

A vantagem nesta técnica está em predir como a fraude ocorre. A desvantagem está na possibilidade de descobrir somente fraudes já conhecidas, pois os dados serão comparados levando em conta as informações obtidas anteriormente.

O outro ramo na detecção de fraudes ocorre por meio de comparação de valores sem muita informação sobre os dados atuais ou anteriores. Como principal exemplo, um desvio no padrão comportamental de alguma variável pode ser identificado comparando seus dados com outras variáveis similares.

Sua principal vantagem é a disponibilidade de um amplo número de algoritmos destinados para a tarefa [Fawcett and Provost 1997]. O problema apresentado pela técnica é a possibilidade do indivíduo fraudador conhecer e inserir dados fraudulentos de maneira em que o sistema não consiga identificá-lo como um usuário malicioso, não sendo tão eficiente quanto a primeira técnica, que utiliza informações prévias para prever novas situações.

Provost, ao comentar sobre o trabalho de [Bolton et al. 2002], indica que é importante não visualizar a detecção de fraudes somente como uma área, mas desmembrá-la em sub-áreas para promover a interdisciplinariedade. Com isto, constata-se que a detecção de fraudes não possui uma técnica universal, pois ela contém diversas abordagens e mutações.

3. Metodologia

Ao primeiro momento do trabalho de revisão sistemática, o planejamento da estratégia de pesquisa norteia a procura de publicações na área abordada. Esta seção é destinada a detalhar o processo metodológico utilizado para orientar a revisão sistemática proposta.

A revisão da literatura foi baseada no trabalho apresentado por [Kitchenham and Charters 2007], onde os elementos de pesquisa são definidos para desenvolver e relatar a revisão.

A revisão sistemática é, de acordo com [Kitchenham 2004], uma forma de identificar, avaliar e interpretar todas as pesquisas relevantes para uma determinada situação.

A autora indica que todos os estudos individuais em determinada área são categorizados como estudos primários, e as revisões sistemáticas, são chamadas de estudos secundários.

As razões para desenvolver revisões sistemáticas são: (1) sumarizar as tecnologias e técnicas existentes; (2) identificar as lacunas presentes nas pesquisas para sugerir novos estudos; (4) prover um arcabouço para os autores obterem embasamento científico; e (5) examinar se as evidências empíricas dão suporte ou contradizem as hipóteses teóricas.

Para ajudar a selecionar o material para esta revisão sistemática, questões de pesquisa (QP) foram desenvolvidas, seguindo o modelo de revisões sistemáticas proposto por [Kitchenham and Charters 2007]. As questões de pesquisa estão descritas a seguir:

- **QP1:** *Quais são as áreas de detecção de fraudes mais estudadas na literatura?*
- **QP2:** *Como a literatura categoriza as técnicas de detecção de fraudes?*
- **QP3:** *Quais foram os problemas mais relatados pelos autores?*
- **QP4:** *Como os autores testaram e validaram suas pesquisas?*

- **QP5:** *Em qual área há pouca abordagem no estudo de detecção de fraudes?*
- **QP6:** *Há espaço para futuras pesquisas na área?*

Foram selecionadas as bibliotecas digitais abaixo para embasar a pesquisa. O motivo da escolha foi a grande quantidade de material publicado com relevância científica.

- ACM Digital Library¹
- IEEE Xplore Digital Library²
- ScienceDirect³
- SpringerLink⁴

A tarefa para selecionar os artigos pode ser visualizada no diagrama da Figura 2, onde as etapas foram divididas em início, desenvolvimento e conclusão. Na parte inicial, o tema é definido e publicações naquele tema são pesquisadas. Posteriormente, se após a busca por artigos a base de referências não estiver sólida para um bom estudo, a etapa de busca é refeita até obter uma boa base do Estado da Arte na área. Por fim, os artigos selecionados são estudados.

Como critérios de seleção e ordenação para a pesquisa, a revisão escolheu os artigos com maior número de citações e relevância para a área.

O principal critério de seleção foi a proximidade com o tema destacado na introdução deste trabalho, onde a detecção de fraudes deveria ser a principal abordagem do artigo.

Realizando uma exceção, os principais artigos que tratam do tema de detecção de fraudes foram inclusos no estudo para serem utilizados, principalmente na seção do referencial teórico, pois eram encontrados como referência na maioria dos trabalhos atuais.

Foram excluídos da revisão os artigos que fugiam do tema proposto, não possuíam citações ou relevância nas bases de dados ou eram anteriores ao ano de 2006. Os critérios de exclusão estão elencados abaixo. Foram excluídos da seleção os artigos contendo assuntos relacionados a detecção de fraudes em:

- Imagens, vídeos ou impressões físicas;
- Contextos biológicos, como análises de DNA e moléculas;
- Componentes eletrônicos;
- Dispositivos de segurança eletrônica relacionados a vírus, *firewalls* e *cyber* ataques.

Para esta revisão sistemática, obteve-se foco em detecção de fraudes em dados computacionais como números e informações em tabelas, arquivos de texto, planilhas eletrônicas, etc. Isso justifica a exclusão de artigos tratando de áreas como processamento de imagens, biologia, eletrônica e segurança de redes de computadores.

[Flegel et al. 2010] demonstraram em seus estudos que técnicas para detectar invasores em redes de computadores, embora relacionadas com técnicas para detectar

¹<http://dl.acm.org/>

²<http://ieeexplore.ieee.org/>

³<http://www.sciencedirect.com/>

⁴<http://link.springer.com/>

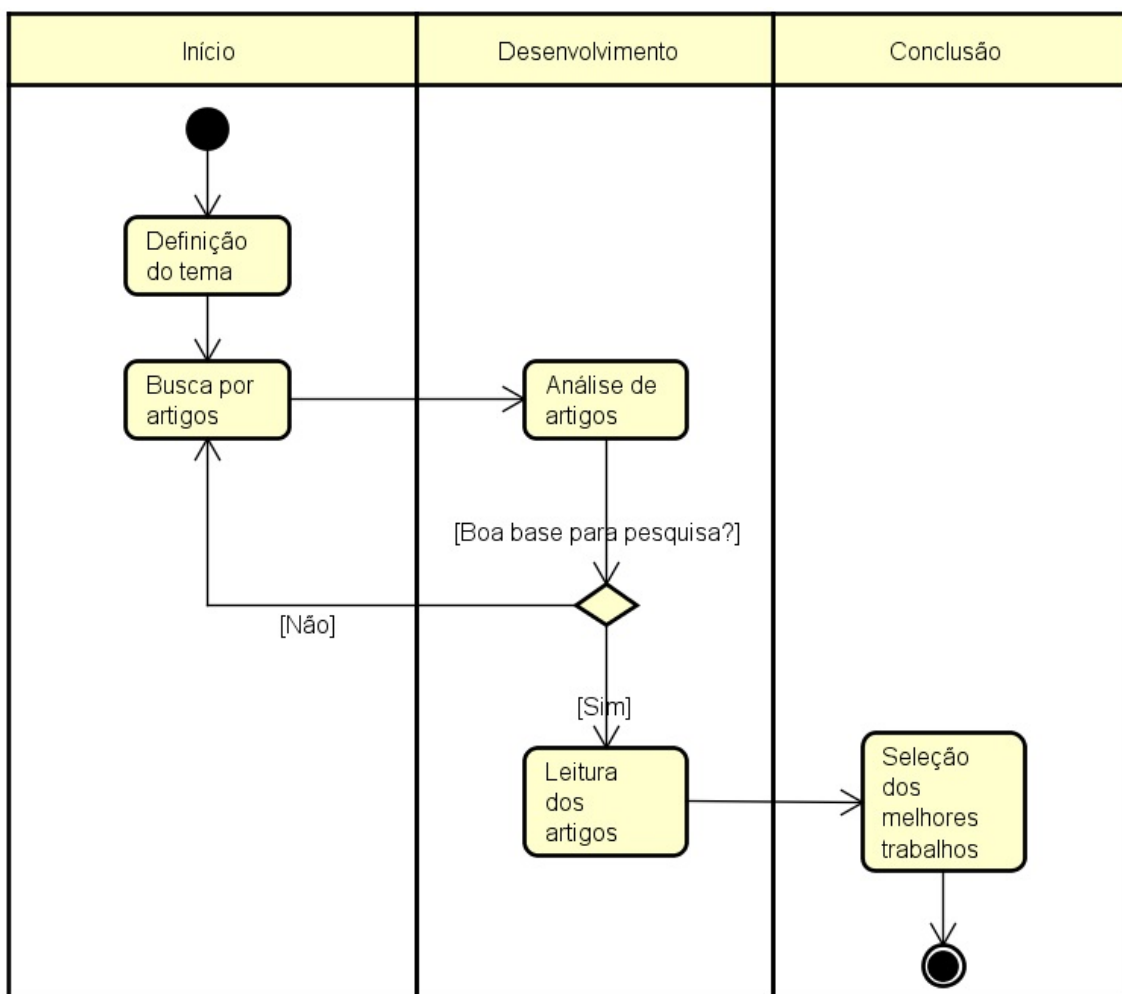


Figura 2. Diagrama de sequência indicando as etapas de seleção de artigos para a pesquisa.

usuários maliciosos no contexto de detecção de fraudes, não são indicadas. A mesma situação ocorre nos contextos apresentados anteriormente, como detecção de anomalias em imagens, componentes eletrônicos (com roteadores inclusos) e sistemas biológicos.

Outro fator que levou a pesquisa de publicações a excluir os fatores anteriores foi o grande número de publicações focadas em detecção de fraudes em dados financeiros, que se aproximam do objetivo geral deste trabalho.

Para a busca de publicações, foram considerados somente trabalhos que realizaram uma revisão no Estado da Arte em detecção de fraude, na língua inglesa e publicados no período entre 2006 e agosto de 2016. As palavras chave *fraud detection survey* foram utilizadas para a busca, que obteve artigos selecionados com a leitura na respectiva ordem: título, resumo e artigo completo.

Foram considerados somente trabalhos em que nenhum novo método ou algoritmo era apresentado ou testado, para aumentar a confiabilidade e imparcialidade dos autores.

Na primeira fase da pesquisa, foi considerada a utilização da combinação das palavras chave a seguir, que posteriormente foram eliminadas da metodologia, pois não

retornaram resultados satisfatórios:

- *fraud detection AND state of art OR systematic review OR meta analysis*;
- *anomaly detection AND survey OR state of art OR systematic review OR meta analysis*;
- *outlier detection AND survey OR state of art OR systematic review OR meta analysis*;
- *deception detection AND survey OR state of art OR systematic review OR meta analysis*.

Os resultados contendo os temas *anomaly*, *outlier* e *deception detection* juntamente com *survey* retornaram trabalhos duplicados em comparação com a pesquisa utilizando as palavras chave *fraud detection survey* ou fora do escopo, onde a grande parte foi eliminada da seleção através dos métodos de exclusão citados anteriormente. Por esta razão, essas palavras chave não foram consideradas para a pesquisa de artigos.

Outras palavras que podem significar revisões sistemáticas na língua inglesa são *state of art*, *systematic review* ou *meta analysis*. Contudo, a utilização dessas palavras chave também se mostrou obsoleta em comparação à palavra *survey*, pois trouxe muitos resultados duplicados ou em áreas indesejadas para esta revisão sistemática, como processamento de imagens, biologia, eletrônica e segurança de redes de computadores.

Portanto, o conjunto de palavras chave que obteve resultados satisfatórios para a revisão sistemática foi:

- *fraud detection survey*.

Conforme demonstra a Figura 3, no início da revisão sistemática, foram encontrados 101 artigos com potencial para estruturar este trabalho. Destes, dois não estavam disponíveis para consulta. Após a leitura do título dos 99 artigos restantes, 49 foram excluídos seguindo os critérios de exclusão. Posteriormente foi realizada a leitura do resumo dos artigos. Destes, 22 trabalhos foram selecionados para prosseguir a revisão sistemática proposta por este trabalho. Os trabalhos estão divididos entre conferências e revistas, conforme demonstra a Tabela 1.

Tabela 1. Artigos publicados em conferências e revistas

Categoria	Trabalhos	Porcentagem
Conferência	12	55%
Revista	10	45%

4. Estado da Arte

Esta seção irá apresentar os estudos de autores na área de detecção de fraudes. Conforme descrito na seção de metodologia, foram considerados artigos que realizaram uma revisão sistemática na literatura sobre o tema.




Figura 3. Etapas de exclusão dos artigos, seguindo critérios.

4.1. Revisões sistemáticas gerais em detecção de fraudes

De acordo com o *Basel Committee on Bank Supervision*, existem fraudes de nível interno e externo. Fraudes em nível interno se referem às ocorridas quando empregados cometem fraudes contra a própria organização. Fraudes de nível externo correspondem a clientes ou indivíduos distantes das organizações que obtém proveito de falhas variadas [Abdallah et al. 2016].

Ainda conforme [Abdallah et al. 2016], o índice de fraudes continua a crescer. De 2011 para 2016, por exemplo, obteve-se um acréscimo de 15% nas fraudes cometidas em sistemas de telecomunicações.

[Abdallah et al. 2016] elencaram as áreas mais presentes em trabalhos anteriores e as tecnologias mais utilizadas em cada contexto. Segundo os autores, fraudes ocorridas em bancos compõem 53% dos estudos, seguidas por fraudes em seguradoras (31%), em comércio eletrônico (10%) e em sistemas de telecomunicações (6%). O gráfico com as informações está demonstrado na Figura 4.

A justificativa do maior índice de fraudes ocorrer em operações bancárias é o

crescente aumento da utilização de cartões de crédito, que expandiram rapidamente nas últimas duas décadas [Wongchinsri and Kuratach 2016].




Figura 4. Áreas com maior pesquisa em detecção de fraudes. Fonte: [Abdallah et al. 2016]

[Flegel et al. 2010] indicam que na indústria, a abordagem de detecção de fraudes não reflete a grande importância que a literatura dá para o tema. Fora do contexto acadêmico, a maior parte do processo de descobrir uma fraude é realizado por um humano que utiliza ferramentas populares para controle de dados, como planilhas eletrônicas *Microsoft Excel* ou *OpenOffice Calc*.

Os autores ressaltam que tecnologias para detectar e coibir tentativas de invasão em sistemas de redes de computadores não podem ser comparadas - ou suas técnicas utilizadas - com detecção de fraudes em dados financeiros. [Flegel et al. 2010] diferenciam as características de dados financeiros como sendo estruturas definidas de uma forma diferente com as características que usuários tentando atacar *hardwares* de computadores apresentam.

Contradizendo os argumentos de [Flegel et al. 2010], [Pejic-Bach 2010] realiza uma revisão sistemática considerando artigos do período de 1956 à 2009 e chega a conclusões diferentes. A autora relata que a academia e a indústria dão grande atenção para detecção de fraudes, e categoriza as subáreas de maneira similar a [Abdallah et al. 2016].

[Bansal 2016] classificam as principais abordagens da detecção de fraudes como aplicações para: cartões de crédito, seguradoras, sistema interno de empresas, sistema médico e de saúde e equipamentos industriais. O artigo apresenta as tecnologias para resolver os problemas apresentados, com enfoque na detecção de *outliers*.

Categorizando os *outliers*, os autores denominam: *Point Outliers*, *Contextual Outliers* e *Collective Outliers*, que são, respectivamente, *outliers* individuais (valores com informações muito divergentes da maioria), *outliers* por contexto (um valor diferente dos outros, porém aceitável naquele contexto, ex: um usuário que gastou além do normal no dia 24 de dezembro, véspera de natal) ou *outliers* que realizam uma formação de cartel

fora do padrão esperado (similar ao individual, onde um grupo de indivíduos possui uma atividade similar divergente da maioria).

[Bansal 2016] indicam que para detectá-los, as formas mais difundidas na literatura são: *Distance based outlier detection*, *Clustering based outlier detection*, *Density based outlier detection* e *Depth based outlier detection*.

4.2. Técnicas de detecção de fraudes

4.2.1. Tipos comuns de anomalias em dados

[Ahmed et al. 2015] identificam em sua revisão da literatura em detecção de anomalias os três tipos de anomalias mais comuns.

Os grupos são similares aos grupos identificados por [Bansal 2016]. [Ahmed et al. 2015] indicam: anomalia pontual, onde um dado está fora do padrão de um conjunto de dados; a anomalia contextual, onde um dado está fora do padrão de um conjunto de dados considerando o seu contexto (usando como exemplo, novamente, o acréscimo de gastos com cartões de crédito no dia 24 de dezembro, que é considerado uma exceção por contexto pelas compras natalinas); e anormalidades coletivas, onde espécies de cartões e conjuntos de dados são identificados fora do padrão dos demais dados.

4.2.2. Mineração de dados por aprendizado supervisionado (algoritmos classificadores) e não-supervisionado (algoritmos de agrupamento)

Focando-se em detecções de anomalias, [Ahmed et al. 2015] limitam-se a trabalhar com dados não-supervisionados, que são dados sem classificações a respeito de seus conteúdos.

Os autores indicam que a aplicação de técnicas de clusterização (como o algoritmo mais popular para a área, o *K-Means*) é comum para detectar anomalias nesses tipos de dados. Além das classificações apresentadas por [Abdallah et al. 2016], o estudo indica a fraude no mercado de ações como um nicho entre os criminosos, onde pessoas que possuem informações internas antes que o público geral as utilizam para realizar mudanças nos lucros.

Em contraste com os dados não-supervisionados, os dados supervisionados são informações em que os pesquisadores possuem controle de quais valores representam ou não uma fraude.

Um exemplo de dados supervisionados são tabelas com informações de gastos em um cartão de crédito, onde o banco especificou previamente quais dados são considerados fraudulentos [Akoglu et al. 2015] e [Branco 2016]. Para os dados supervisionados (onde uma boa parte das informações contém algum registro classificador como "fraude"), os algoritmos especializados são treinados utilizando aprendizado de máquina para tentar prever novos valores com o classificador desconhecido.

Enquanto os métodos de clusterização (não supervisionados) tentam identificar padrões por não possuírem essa informação, os algoritmos de dados de classificação su-

pervisionados realizam o treinamento sabendo quais informações são fraudulentas ou verossímeis.

O problema apresentado pela utilização de dados supervisionados é a dificuldade de encontrar novas anomalias [Ahmed et al. 2015]. Ao final da revisão sistemática, os autores indicam que uma técnica universal para detectar fraudes ainda está para ser encontrada, devido à grande variação no contexto da anormalidade.

[Rebahi et al. 2011] discutem a abordagem baseada em aprendizado, similar ao método supervisionado e computacionalmente mais simples. Os autores indicam que a característica principal desta técnica está na necessidade de definir regras iniciais. Portanto, dados e conhecimentos de atividades fraudulentas são necessários para construir alarmes, que serão disparados quando dados naquelas características forem encontrados no sistema.

[Pejic-Bach 2010], [Wang 2010] e [Raj and Portia 2011] analisaram trabalhos que utilizam algoritmos destinados a detectar fraudes. Com as pesquisas, constata-se uma grande frequência na utilização de determinadas abordagens, como as técnicas de redes neurais, lógica *fuzzy*, algoritmos genéticos, computação evolucionária (ou evolutiva), programação genética e otimização por nuvem de partículas. [Raj and Portia 2011] constataram, além das técnicas apresentadas anteriormente, os métodos de aprendizado por Inferência Bayesiana, Teoria de Evidência de Dempster-Shafer, *BLAST-SSAHA Hybridization* e Modelo oculto de Markov.

A tabela 2 representa as abordagens e técnicas mais utilizadas em cada situação. Todavia, é importante ressaltar que os algoritmos indicados como técnica para determinada categoria podem ser utilizados por outro método ou mesmo em conjunto.

Tabela 2. Técnicas e categorias mais utilizadas. Fonte: [Abdallah et al. 2016]

Método	Categoria	Técnica
Supervisionado	Classificação	Árvores de decisões Redes neurais artificiais Modelo oculto de Markov Inferência Bayesiana
Não-supervisionado	Clusterização	Lógica Fuzzy K-Means (média) K-NN (vizinhos próximos)

Para testar as técnicas e novos algoritmos, muitos autores não utilizam de dados reais, obtidos por eles, e recorrem a algum repositório de *datasets*. O mais conhecido na área de mineração de dados é o UCI Machine Learning Repository⁵, que contém diversos conjuntos de dados para métodos supervisionados e não-supervisionados.

Realizando uma generalização, a Figura 4, proposta por [Allan and Zhan 2010] demonstra que os dados classificados como fraudulentos geralmente aparecem em menor número em comparação com dados legais. O conjunto de dados utilizado para o apren-

⁵<https://archive.ics.uci.edu/ml/datasets.html>

dizado de um algoritmo supervisionado é geralmente menor do que os dados que serão utilizados para treinamento/teste ou uma situação real.

Em casos de dados não-supervisionados, não há o campo *label* do atributo, onde geralmente teríamos a informação de que aquele valor é fraude ou não-fraude.

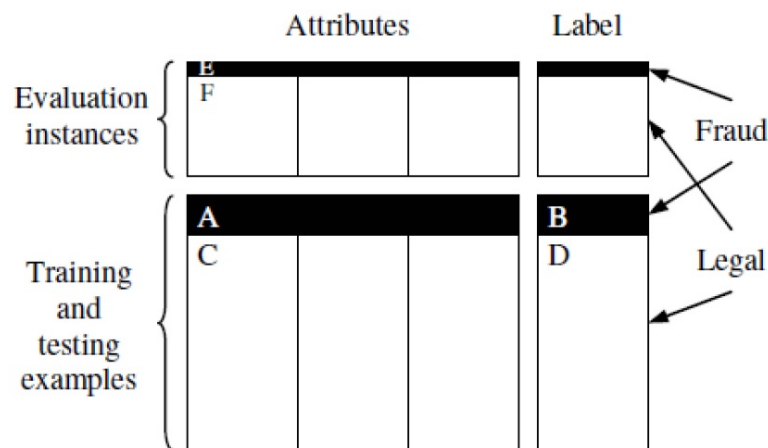


Figura 5. Distribuição padrão na característica dos dados. Fonte: [Allan and Zhan 2010]

[Allan and Zhan 2010] também indicam que é possível a maioria de cruzamento de técnicas, onde podemos executar métodos semi-supervisionados somente com informações de dados não fraudulentos, métodos supervisionados sendo aplicados em sequência e métodos supervisionados e não-supervisionados sendo utilizados em conjunto de maneira híbrida

4.3. Áreas de detecção de fraudes

Realizando uma pesquisa de artigos na área de detecção de fraudes com sistemas inteligentes no período de 1956 à 2009, [Pejic-Bach 2010] encontrou 36 artigos após a aplicação de seus filtros de pesquisa, que foram rigorosos para eliminar os mais de 2000 artigos encontrados e conseguir trabalhos extremamente relevantes.

Como um dos últimos critérios de exclusão adotados, [Pejic-Bach 2010] decidiu considerar apenas os trabalhos nos quais os autores possuíam mais de dez citações e eram autores de pelo menos 3 artigos similares. Como uma constatação, a autora indicou que dos 82 autores restantes, apenas uma era uma mulher.

Devido ao seu filtro divergente da maioria das revisões sistemáticas da área, [Pejic-Bach 2010] indicou que a grande parte dos artigos encontrados tratavam sobre a detecção de fraudes em sistemas de telecomunicação (dez artigos), seguido por fraudes em auditorias e seguradoras, posteriormente por sistemas financeiros e uma pequena parte em outras aplicações, como comércio eletrônico.

Outra razão do aparecimento dos sistemas de telecomunicação, auditorias e seguradores em maior número ao de sistemas financeiros pode ter sido o fato do período temporal para procura de artigos, pois aumento significativo no uso de cartões de crédito ocorreu depois da década de 80.

4.3.1. Sistemas financeiros e cartões de crédito

[Gullkvist and Jokipii 2013] apresentam a importância de indicadores de risco para auxiliar as corporações a detectar fraudes em setores financeiros. Segundo os autores, as fraudes podem ser prevenidas, detectadas e investigadas. Em qualquer caso, é importante que os sistemas forneçam aos humanos responsáveis por categorizar ações fraudulentas o indício de risco na fase mais inicial possível.

Para setores específicos de detecção de fraudes, a identificação de anomalias em tempo real se demonstrou importante. [Edge and Falcone Sampaio 2009] realizaram um levantamento das técnicas financeiras no contexto de detecção de fraudes. Em cartões de crédito, o maior interesse nas pesquisas acontece no ramo de detecção de fraudes em tempo real, pois o prejuízo ocorrido após algum gasto ou transação indevida ser aprovada pode ser irreversível ou a correção mais custosa do que o valor perdido.

Desenvolvendo um panorama geral na área, [Allan and Zhan 2010] compartilham seus resultados e constataam um problema para a literatura sobre o fato da detecção de fraudes em cartões de crédito possuir técnicas privadas para a indústria. Segundo os autores, as companhias bancárias não possuem interesse em compartilhar seus métodos para detectar fraudadores pois essas informações poderiam ser utilizadas de forma indevida por criminosos.

[Perlich et al. 2007] e [Kanapickiene et al. 2015] realizam trabalhos relacionando as áreas financeiras com a introdução de suas técnicas para detectar fraudes. Nas constatações, indicam que os indivíduos fraudadores devem ser considerados como internos ou externos à empresa, similarmente a categorização da *Basel Committee on Bank Supervision*.

Por conter dois tipos de características, cada uma das abordagens de fraudes deve ser considerada distinta da outra. Em fraudadores internos, englobam-se os próprios funcionários e gerentes das organizações. Em usuários externos, são considerados os clientes mal intencionados ou criminosos.

4.3.2. Assistência médica

[Bauder et al. 2016] e [Li et al. 2008] realizaram revisões na literatura visando ampliar a abordagem de detecção de fraudes na área da saúde. Ambos os estudos constataram que a área financeira de detecção de fraudes é geralmente adaptada de forma genérica para ser utilizada no contexto da saúde.

Determinadas abordagens são ineficientes em certos casos, indicando uma necessidade de aprofundamento nos estudos. [Bauder et al. 2016] também indicam que são utilizadas técnicas supervisionadas, não-supervisionadas e híbridas no contexto de saúde, onde geralmente as técnicas não-supervisionadas prevalecem, devido a dificuldade de obter determinados dados médicos.

4.3.3. *Big data* e redes sociais

[Feily et al. 2009], [Mahmood and Afzal 2013] e [Sharma and Mangat 2015] relacionam o crescimento do termo *big data* com a necessidade de inspecionar os dados para detectar problemas.

A maior dificuldade, segundo os autores, é gerenciar a grande quantidade de informação - geralmente desordenada - que a nova abordagem da computação produz. [Sharma and Mangat 2015] ainda indicam em suas pesquisas que os próprios dados provenientes de *big data* podem ser utilizados para auxiliar mecanismos de detecção de fraudes.

Para ilustrar a situação anterior, [Liu and Chawla 2015] e [Yu et al. 2016] discutem que as novas abordagens em detecção de fraudes provavelmente acontecerão em redes sociais.

Com uma grande quantidade de dados para analisar, as novas ferramentas de comunicação proporcionam oportunidades para detectar grupos de pessoas e premeditar suas atitudes, podendo ser utilizadas para prevenir ataques terroristas, por exemplo. Os autores ressaltam que as técnicas de anomalias pontuais e grupos de anomalias estão presentes nessa área, onde os algoritmos baseados em grafos são os mais utilizados.

4.4. Resposta às principais perguntas

Após o término da revisão sistemática, as questões de pesquisas levantadas na seção de metodologia podem ser respondidas. As constatações estão presentes abaixo:

- **QP1:** *Quais são as áreas de detecção de fraudes mais estudadas na literatura?*
A maioria dos trabalhos obteve as seguintes áreas de fraudes em comum: bancos, dispositivos de telecomunicação, seguradoras, comércio eletrônico, leilões virtuais, mercado de ações e dados jurídicos. Os autores, com seus respectivos países, que citaram determinadas áreas estão relacionados nas tabelas 3 e 4.
- **QP2:** *Como a literatura categoriza as técnicas de detecção de fraudes?*
Genericamente, os algoritmos para detectar fraudes realizam cálculos em dados supervisionados e não-supervisionados. Em métodos baseados em dados supervisionados, o pesquisador já possui a informação de qual dado é fraudulento. Em métodos baseados em dados não-supervisionados, ocorre o contrário. Há alguns autores que propõem uma abordagem híbrida ou por meio de regras.
- **QP3:** *Quais foram os problemas mais relatados pelos autores?*
Algumas áreas específicas não possuem uma abordagem mais aprofundada. Geralmente, os pesquisadores utilizam algoritmos genéricos para detectar fraudes nos mais variados contextos. Um exemplo é a grande utilização de algoritmos das áreas econômicas e financeiras (exaustivamente estudadas) sendo aplicados para detectar fraudes em sistemas de saúde.
- **QP4:** *Como os autores testaram e validaram suas pesquisas?*
Os autores utilizaram dados variados para cada contexto, como dados para técnicas supervisionadas e não-supervisionadas. Para comparar e validar com

Tabela 3. Áreas mais abordadas pelos autores no período entre 2006 e 2016.

Áreas	Autores	País
Bancos ou cartões de crédito	[Abdallah et al. 2016]	Malásia
	[Ahmed et al. 2015]	Austrália
	[Akoglu et al. 2015]	EUA
	[Allan and Zhan 2010]	EUA
	[Bansal 2016]	Índia
	[Branco 2016]	Portugal
	[Edge and Falcone Sampaio 2009]	Reino Unido
	[Pejic-Bach 2010]	Croácia
	[Perlich et al. 2007]	EUA e Brasil
	[Raj and Portia 2011]	Índia
Seguradoras	[Abdallah et al. 2016]	Malásia
	[Ahmed et al. 2015]	Austrália
	[Akoglu et al. 2015]	EUA
	[Bansal 2016]	Índia
	[Branco 2016]	Portugal
	[Pejic-Bach 2010]	Croácia
Cuidados da saúde	[Abdallah et al. 2016]	Malásia
	[Bansal 2016]	Índia
	[Bauder et al. 2016]	EUA
	[Li et al. 2008]	EUA
	[Pejic-Bach 2010]	Croácia
Telecomunicação	[Abdallah et al. 2016]	Malásia
	[Ahmed et al. 2015]	Austrália
	[Akoglu et al. 2015]	EUA
	[Allan and Zhan 2010]	EUA
	[Branco 2016]	Portugal
	[Pejic-Bach 2010]	Croácia
Comércio eletrônico	[Abdallah et al. 2016]	Malásia
	[Akoglu et al. 2015]	EUA
	[Branco 2016]	Portugal
	[Pejic-Bach 2010]	Croácia
Leilões virtuais	[Abdallah et al. 2016]	Malásia
	[Pejic-Bach 2010]	Croácia
Mercados de ações	[Ahmed et al. 2015]	Austrália
	[Pejic-Bach 2010]	Croácia

outros algoritmos, os autores executam técnicas conhecidas da literatura em dados de sua escolha e após, repetem o teste utilizando seus novos métodos para comparação de valores. Geralmente, os algoritmos são comparados utilizando bases de dados fornecidas na internet para estudos, porém alguns autores recorrem a

Tabela 4. Áreas mais abordadas pelos autores no período entre 2006 e 2016.

Áreas	Autores	País
Dados financeiros ou empresariais	[Akoglu et al. 2015]	EUA
	[Allan and Zhan 2010]	EUA
	[Branco 2016]	Portugal
	[Edge and Falcone Sampaio 2009]	Reino Unido
	[Flegel et al. 2010]	Alemanha e Austrália
	[Gullkvist and Jokipii 2013]	Finlândia
	[Kanapickiene et al. 2015]	Lituânia
	[Pejic-Bach 2010]	Croácia
	[Wang 2010]	China
Redes sociais	[Feily et al. 2009]	Malásia
	[Liu and Chawla 2015]	EUA e Austrália
	[Rebahi et al. 2011]	Alemanha e França
	[Yu et al. 2016]	EUA
Big data	[Mahmood and Afzal 2013]	Paquistão
	[Sharma and Mangat 2015]	Índia
Redes de computadores	[Akoglu et al. 2015]	EUA
	[Allan and Zhan 2010]	EUA
	[Branco 2016]	Portugal
Equipamentos industriais	[Bauder et al. 2016]	EUA
Terrorismo	[Allan and Zhan 2010]	EUA

dados reais para obter mais acurácia em seus resultados.

- QP5:** *Em qual área há pouca abordagem no estudo de detecção de fraudes?*
 Em setores específicos e que estão em crescimento de interesse pela comunidade. Para padronizar os resultados de futuros autores, dados de *benchmarks* seriam possibilidades para novos estudos. A criação de um padrão mínimo a ser seguido por autores para realizar experimentos seria um passo importante para a área, pois além de não possuírem dados padronizados, os estudos anteriores não demonstram uma uniformidade na execução.
- QP6:** *Há espaço para futuras pesquisas na área?*
 Sim. Embora os principais tópicos tenham sido muito discutidos, melhorias gerais nas técnicas ainda são possíveis. Reduzir a incidência de falsos negativos e falsos positivos sem gasto excessivo de recursos humanos e computacionais são esperados para o futuro da área. Junto a esse fator, realizar a detecção de fraude em tempo real, coibindo os falsos negativos e falsos positivos de maneira satisfatória também é almejado para novas publicações. Finalmente, como mencionado por autores da área, a adaptação das técnicas de detecção de fraudes amplamente estudadas, como setores financeiros, podem ser aplicadas em setores biológicos ou da medicina.

5. Discussão

Nas seções anteriores, observamos o estado das pesquisas relacionadas à detecção de fraudes. Conforme as observações realizadas, esta seção visa discutir os fatores em comum entre os trabalhos e os dados obtidos.

O principal desafio apontado pela maioria dos autores é a evolução das técnicas utilizadas pelos fraudadores para burlar os sistemas.

Em estudos constatados por corporações bancárias, o comportamento esperado por fraudadores demonstrou uma mutação quando os criminosos entenderam as técnicas para detectá-los [Bolton et al. 2002]. Indivíduos que em outrora utilizavam cartões de crédito somente para efetuar compras com a intenção de não pagá-las, perceberam que poderiam pagar compras iniciais para serem classificados como usuários comuns. Dessa maneira, possuiriam maior margem para fraudar no futuro.

É importante ressaltar que a maioria dos estudos indicou que a verificação final se algum dado representa ou não uma fraude é uma tarefa recomendada para um ser humano, que pode ser auxiliado por uma ferramenta computacional, como um algoritmo.

Entendendo o problema de mutação nas técnicas criminosas, constatamos um contraste com a engenharia de software tradicional, que possui um processo de produção padrão, onde ocorre etapas de análise, projeto, codificação, implementação e testes [Sommerville 2011]. Dessa maneira, a constante evolução das características de usuários fraudulentos pode se tornar um desafio para ser englobado em um modelo de desenvolvimento tradicional de software.

Ao analisar os trabalhos desenvolvidos na área de detecção de fraudes, não foi possível constatar a presença de um padrão no conjunto de dados que pudesse ser utilizado por diversos algoritmos para computação e comparação de valores. Em seus trabalhos, os autores utilizaram os mais variados tipos de dados, sendo possível identificar duas grandes características em comum: houveram autores que utilizaram dados controlados, possivelmente criado por eles; e dados não fictícios, onde utilizaram suas técnicas e algoritmos em informações providas de empresas e problemas reais.

O problema, porém, está no fato em que os autores comparam os seus algoritmos com os já existentes na literatura utilizando os dados que lhes são convenientes. Esta revisão sistemática propõe como sugestão para trabalhos futuros desenvolver e apresentar um conjunto de dados que possa servir como um *benchmark*, que diversos pesquisadores possam realizar seus estudos nos mesmos ambientes ou com as mesmas condições, com a finalidade de obter testes padronizados.

O tempo de processamento dos algoritmos pode ser ignorado para alguns casos, como a maioria dos algoritmos de clusterização. Em alguns sistemas de classificação, como os que necessitam do aviso imediato de alguma fraude (transação bancária, telefonema clonado, etc), o tempo computacional pode ser relevante.

Um dos fatores que contribui com o aumento do processamento computacional é a maldição da dimensionalidade, onde muitos atributos desprezíveis no conjunto de dados levam o algoritmo a ter menor eficiência [Hodge and Austin 2004].

A tarefa de selecionar os atributos que levarão para o algoritmo algum acréscimo de informação para um melhor resultado deve executada por um humano. Nenhum algo-

ritmo de pré-processamento é inteligente o suficiente para compreender os dados de uma base e selecionar automaticamente os dados que achar relevante.

Portanto, na etapa de pré-processamento das informações, uma pessoa que possui conhecimento sobre os dados da base pode realizar a seleção de atributos. A revisão sistemática deste trabalho não encontrou na literatura estudos específicos para orientar a etapa de pré processamento. Das ferramentas mais utilizada para mineração de dados (Weka⁶ e linguagem R⁷), nenhuma apresenta um *framework* dedicado eficiente para pré-processamento.

6. Conclusão

Foi realizada uma revisão sistemática na área de detecção de fraudes. Pesquisas realizadas para dar o panorama na área foram estudadas e discutidas. Ao obter os principais artigos publicados na área, constatamos um crescimento no índice de publicações na área acadêmica após o ano de 2010. Isto demonstra que o assunto está em ascensão de interesse.

Em conclusão, o trabalho indica que a área, embora muito estudada, ainda concentra amplo poder para novas pesquisas. Um setor de pesquisa em ascensão é a adaptação das técnicas difundidas e testadas com experiências positivas para contextos específicos, como dados governamentais.

Como a maioria dos estudos constataram que a influência para algum desenvolvimento científico em alguma área de detecção de fraude vem do interesse financeiro, os sistemas corporativos bancários, de prestação de seguros e de telecomunicações foram os mais citados, pois a indústria destes setores geram altos valores.

Seguido dos três sistemas atuais, o setor de *e-commerce* vem despertando interesse acadêmico e comercial, pois é considerado um setor relativamente novo, se comparado ao sistema de cartão de crédito. Também podemos lembrar que o comércio virtual consegue englobar muitas categorias citadas como áreas de possíveis fraudadores, com a possibilidade de generalização dos setores.

Junto com a importância do assunto verificada após os estudos, grande parte dos autores destacaram que o problema computacional ocorrido em todos os casos é a não detecção de todos os falsos negativos (onde ações fraudulentas não são detectadas), bem como a classificação equivocada de falsos positivos (ações legítimas caracterizadas, erroneamente, como fraudulentas) com aceitável gasto de recurso. Desta forma, novas abordagens são necessárias para a continuidade do tema.

Em trabalhos futuros, pretende-se continuar a pesquisa em detecção de fraudes, aplicando técnicas para auxiliar órgãos públicos a descobrir irregularidades em dados de auditoria e controle.

Como em praticamente todos os casos de decisão entre dados fraudulentos e não-fraudulentos é atribuída para uma pessoa humana, os algoritmos e técnicas servem como ferramentas. Com a revisão sistemática, não foram encontrados conjuntos de ações gerais para os detectores de fraudes utilizarem das ferramentas disponíveis na literatura,

⁶<http://www.cs.waikato.ac.nz/ml/weka/>

⁷<https://www.r-project.org/>

pois os autores geralmente publicam suas descobertas de maneira individual e com uma segregação entre o acadêmico e o profissional.

Referências

- Abdallah, A., Maarof, M. A., and Zainal, A. (2016). Fraud detection system: A survey. *Journal of Network and Computer Applications*, 68:90–113.
- Ahmed, M., Mahmood, A. N., and Islam, M. R. (2015). A survey of anomaly detection techniques in financial domain. *Future Generation Computer Systems*, 55:278–288.
- Akoglu, L., Tong, H., and Koutra, D. (2015). *Graph based anomaly detection and description: A survey*, volume 29.
- Allan, T. and Zhan, J. (2010). Towards fraud detection methodologies. *2010 5th International Conference on Future Information Technology, FutureTech 2010 - Proceedings*.
- Bansal, R. (2016). Outlier Detection : Applications and Techniques in Data Mining.
- Bauder, R., Khoshgoftaar, T. M., and Seliya, N. (2016). A survey on the state of health-care upcoding fraud analysis and detection. *Health Services and Outcomes Research Methodology*, pages 1–25.
- Bolton, R. J., Hand, D. J., Provost, F., Breiman, L., Bolton, R. J., and Hand, D. J. (2002). Statistical Fraud Detection: A Review. *Statistical Science*, 17(3):235–255.
- Branco, P. (2016). A Survey of Predictive Modeling on Imbalanced Domains. 49(2):1–50.
- Chan, P. K., Fan, W., Prodromidis, A. L., and Stolfo, S. J. (1999). Distributed data mining in credit card fraud detection. *IEEE Intelligent Systems and their Applications*, 14(6):67–74.
- Chandola, V., Banerjee, A., and Kumar, V. (2009). Anomaly Detection: A Survey. *ACM Comput. Surv.*, 41(3):15:1—15:58.
- Edge, M. E. and Falcone Sampaio, P. R. (2009). A survey of signature based methods for financial fraud detection. *Computers and Security*, 28(6):381–394.
- Fawcett, T. and Provost, F. (1997). Adaptive Fraud Detection. *Data Mining and Knowledge Discovery*, 1(3):291–316.
- Fayyad, U. M., Piatetsky-Shapiro, G., and Smyth, P. (1996). Advances in knowledge discovery and data mining. chapter From Data Mining to Knowledge Discovery: An Overview, pages 1–34. American Association for Artificial Intelligence, Menlo Park, CA, USA.
- Feily, M., Shahrestani, A., and Ramadass, S. (2009). A survey of botnet and botnet detection. *Proceedings - 2009 3rd International Conference on Emerging Security Information, Systems and Technologies, SECURWARE 2009*, pages 268–273.
- Flegel, U., Vayssière, J., and Bitz, G. (2010). A State of the Art Survey of Fraud Detection Technology. *Insider Threats in Cyber Security*, 49:73–84.
- Gullkvist, B. and Jokipii, A. (2013). Perceived importance of red flags across fraud types. *Critical Perspectives on Accounting*, 24(1):44–61.
- Hodge, V. J. and Austin, J. (2004). A survey of outlier detection methodologies. *Artificial Intelligence Review*, 22(2):85–126.

- Kanapickiene, R., Grundiene, Ž., Gimzauskiene, E., Duoba, K., Pavie, X., Pinnington, A., Vilkas, M., Kanapickiene, R., Grundiene, Ž., Kanapickiene, R., and Grundiene, Ž. (2015). The Model of Fraud Detection in Financial Statements by Means of Financial Ratios. *Procedia - Social and Behavioral Sciences*, 213:321–327.
- Kitchenham, B. (2004). Procedures for performing systematic reviews. *Keele, UK, Keele University*, 33(TR/SE-0401):28.
- Kitchenham, B. and Charters, S. (2007). Guidelines for performing Systematic Literature Reviews in Software Engineering.
- Li, J., Huang, K.-Y., Jin, J., and Shi, J. (2008). A survey on statistical methods for health care fraud detection. *Health care management science*, 11(3):275–287.
- Liu, Y. and Chawla, S. (2015). Social Media Anomaly Detection : Challenges and Solutions. *Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 2317–2318.
- Mahmood, T. and Afzal, U. (2013). Security Analytics: Big Data Analytics for Cybersecurity. *2013 2nd National Conference on Information Assurance (NCIA)*, pages 129–134.
- Pejic-Bach, M. (2010). Profiling intelligent systems applications in fraud detection and prevention: Survey of research articles. *ISMS 2010 - UKSim/AMSS 1st International Conference on Intelligent Systems, Modelling and Simulation*, pages 80–85.
- Perlich, C., Rosset, S., Lawrence, R. D., and Zadrozny, B. (2007). High-quantile modeling for customer wallet estimation and other applications. *Proceedings of the 13th ACM SIGKDD international conference on Knowledge discovery and data mining - KDD '07*, page 977.
- Raj, S. B. E. and Portia, a. A. (2011). Analysis on credit card fraud detection methods. *2011 International Conference on Computer, Communication and Electrical Technology (ICCCET)*, pages 152–156.
- Rebahi, Y., Nassar, M., Magedanz, T., and Fester, O. (2011). A survey on fraud and service misuse in voice over IP (VoIP) networks. *Information Security Technical Report*, 16(1):12–19.
- Seyedhossein, L. and Hashemi, M. R. (2010). Mining information from credit card time series for timelier fraud detection. In *Telecommunications (IST), 2010 5th International Symposium on*, pages 619–624.
- Sharma, S. and Mangat, V. (2015). Technology and Trends to Handle Big Data: Survey. *2015 Fifth International Conference on Advanced Computing {&} Communication Technologies*, pages 266–271.
- Sommerville, I. (2011). *Engenharia de Software*. Pearson Brasil, 9th edition.
- Wang, S. (2010). A comprehensive survey of data mining-based accounting-fraud detection research. *2010 International Conference on Intelligent Computation Technology and Automation, ICICTA 2010*, 1:50–53.
- Wongchinsri, P. and Kuratach, W. (2016). A survey - data mining frameworks in credit card processing. In *2016 13th International Conference on Electrical Engeneer-*

ring/Electronics, Computer, Telecommunications and Information Technology (ECTI-CON), pages 1–6.

Yu, R., Qiu, H., Wen, Z., Lin, C.-Y., and Liu, Y. (2016). A Survey on Social Media Anomaly Detection. *arXiv preprint*, 18(1):18.